

Motion Planning — 기말 예상 문제집

강의안 L00–L12 / cheat sheet 지참 가능 · 계산기 사용 불가

2026 Spring

각 강의안(L00–L12)별 출제 가능성 높은 문제 **2개씩** (메인 + 보조), 총 **26문제**. 풀이는 문제 바로 아래.

시험 조건: cheat sheet 지참 가능 → 단순 암기 X, 이해/유도/작은 손계산 위주. 계산기 사용 불가 → 손계산 가능한 수치만.

Contents

Part I — Basic Planning (L00–L03)	2
1 L00. Path Planning Basics	2
[메인] Visibility graph vs Voronoi diagram	2
2 L01. A* / Dijkstra	2
3 L02. PRM, RRT, RRT*	3
4 L03. LPA* / D* Lite	3
Part II — Constraints & Controllability (L04–L05)	4
5 L04. Nonholonomic Constraints	4
6 L05. Controllability & Chained Form	5
Part III — Trajectory & Collision (L06–L09)	7
7 L06. Polynomial Trajectory & Bézier	8
8 L07. Collision Checking	9
9 L08. CHOMP	10
10 L09. Quadrotor Flatness & SFC	10
Part IV — Optimal Control & MPC (L10–L12)	11
11 L10. LQR / iLQR	11
12 L11. Linear MPC Stability	12
13 L12. NMPC & PMP	13

Part I — Basic Planning (L00–L03)

1 L00. Path Planning Basics

[메인] Visibility graph vs Voronoi diagram

★★★

2D 다각형 환경에 5개의 직사각형 장애물이 있고 시작/목표 점이 주어졌다.

(a) Visibility graph의 노드 수와 (최악의 경우) 엣지 수를 식으로 나타내라.

(b) 같은 환경에서 Voronoi diagram이 visibility graph에 비해 어떤 경로 품질 측면에서 유리한가? 그리고 그 단점은?

(a) 직사각형 1개에 꼭짓점 4개 → 5개 장애물에 $5 \times 4 = 20$ 개. 시작/목표 추가 → 노드 $n = 22$. 모든 노드쌍 $\binom{n}{2}$ 중 일부만 연결 → 최악 $O(n^2)$ 엣지 (대략 $\binom{22}{2} = 231$ 의 일부).

(b) Voronoi diagram은 정의상 “가장 가까운 두 장애물 경계로부터 등거리”인 점들 ⇒ **clearance**(장애물과의 여유)를 최대화. 안전한 경로 생성에 유리. 단점: 최단 경로가 아님 (visibility graph는 obstacle vertex로 꺾이는 최단경로를 준다).

[보조] Local minimum과 navigation function

★★★

(a) Attractive + repulsive potential 합으로 만든 potential field에서 robot이 local minimum에 갇히는 환경 예시를 하나 그림으로 설명하라.

(b) Navigation function이 갖춰야 할 4가지 조건을 나열하라.

(a) U자형 (오목) 장애물 안쪽에 robot이 들어가고, 그 정면에 goal이 있는 경우. 두 벽의 반발력이 좌우 대칭으로 robot을 안쪽으로 밀고, 정면 인력은 벽 너머 goal을 가리키지만, robot은 벽 사이의 점에서 합력 = 0이 되어 정지.

(b) Navigation function:

1. **Global minimum at goal:** $U(q_g) = \min_q U(q)$.
2. **No local minima:** 모든 critical point가 goal 또는 saddle.
3. $U \rightarrow \infty$ **near obstacles:** 충돌 방지.
4. **Smooth** (C^2 이상): gradient descent 가능.

2 L01. A* / Dijkstra

[메인] 작은 그래프에서 A* trace

★★★

5-노드 그래프: $S \rightarrow B$ cost 1, $S \rightarrow A$ cost 2, $B \rightarrow G$ cost 4, $A \rightarrow G$ cost 5, $B \rightarrow A$ cost 3. Heuristic: $h(S) = 4, h(A) = 3, h(B) = 2, h(G) = 0$.

A*로 $S \rightarrow G$ 최적 경로를 찾고, 각 iteration의 expand 순서와 open list ($f = g + h$)를 표로 정리하라.

Iter	Expand	Open list 갱신 후 ($f = g + h$)
1	S ($f = 0 + 4 = 4$)	$\{B(1 + 2 = 3), A(2 + 3 = 5)\}$
2	B ($f = 3$)	$\{A(\min(5, 1 + 3 + 3 = 7) = 5), G(1 + 4 + 0 = 5)\}$
3	A ($f = 5$, tie)	$G: g = 2 + 5 = 7 > 5 \rightarrow$ 변화 없음
4	G ($f = 5$)	goal 도달, 종료

최적 경로: $S \rightarrow B \rightarrow G$, cost 5.

[보조] Admissible but not consistent

★★

3-노드 그래프 $A \rightarrow B \rightarrow G$, 비용 $c(A, B) = 1, c(B, G) = 10$. 다음 heuristic 이 admissible 이지만 consistent 가 아님을 보여라.

$$h(A) = 5, h(B) = 1, h(G) = 0.$$

또한 Dijkstra 가 A^* 의 특수 케이스인 이유를 한 줄로 설명하라.

Admissible: 실제 최단거리 $h^*(A) = 11, h^*(B) = 10, h^*(G) = 0$. $h \leq h^*$ 모두 만족 ✓.

Consistent: $h(A) \leq c(A, B) + h(B)$ 검사 $\rightarrow 5 \leq 1 + 1 = 2$? 거짓 $\rightarrow$ consistent 아님.

Dijkstra = A^* with $h(n) = 0$ for all n . $h = 0$ 은 항상 admissible+consistent 이므로 Dijkstra는 A^* 의 자명한 특수 케이스.

3 L02. PRM, RRT, RRT*

[메인] RRT 의사코드 채우기

★

다음 RRT 의사코드의 빈칸 (1)–(3)을 채우고, goal bias의 역할을 설명하라.

```
T = {q_init}
for i = 1..N:
    q_rand = random_config()      # (with goal bias)
    q_near = (1) -----
    q_new = (2) -----
    if (3) ----- :
        T.add_vertex(q_new); T.add_edge(q_near, q_new)
```

- (1) **nearest(T, q_rand)** — 트리 안에서 q_{rand} 에 가장 가까운 노드.
- (2) $q_{near} + \text{step} \cdot (q_{rand} - q_{near}) / \|q_{rand} - q_{near}\|$ — q_{near} 에서 q_{rand} 방향으로 step만큼 전진.
- (3) **collision_free(q_near, q_new)** — 두 점 사이 segment가 자유공간에 있는지.

Goal bias: 5–10% 확률로 $q_{rand} = q_{goal}$ 로 두기. 순수 무작위 샘플은 균등하게 트리를 키우지만 목표 도달이 느림. Goal bias로 트리가 자연스럽게 목표 방향으로 편향 $\Rightarrow$ 수렴 가속.

[보조] RRT*의 rewiring과 asymptotic optimality

★★★

(a) RRT*에서 X_{near} 안의 노드 x_{near} 에 대해 어떤 조건이 성립할 때 부모를 x_{new} 로 바꾸는지 식으로 쓰라.

(b) RRT가 asymptotic optimal이 아닌 이유와 RRT*가 해결하는 방법.

(a) Rewire 조건:

$$\text{cost}(x_{new}) + c(x_{new} \rightarrow x_{near}) < \text{cost}(x_{near})$$

이면 x_{near} 의 부모를 x_{new} 로 변경.

(b) RRT는 첫 발견한 경로를 그대로 유지하며 부모가 바뀌지 않는다 $\Rightarrow$ 최적이지 아닌 비용에 수렴. RRT*는 (i) 새 노드에 대해 X_{near} 내에서 최소 비용 부모 선택, (ii) 새 노드를 통해 더 싸지는 이웃의 부모 재연결(rewire) $\Rightarrow$ almost-sure convergence to optimum.

4 L03. LPA* / D* Lite

[메인] LPA*에서 차단 후 inconsistent 노드



3×3 grid, 4-connectivity, 모든 셀 비용 1, 처음 모두 free. 시작 $S = (1, 1)$, 목표 $G = (3, 3)$. LPA*가 처음 수렴해서 g 값이 시작점부터의 Manhattan 거리와 같다:

$$g = \begin{pmatrix} 0 & 1 & 2 \\ 1 & 2 & 3 \\ 2 & 3 & 4 \end{pmatrix}.$$

이제 셀 (1, 2)가 차단된다.

- (a) 차단 후 inconsistent 해질 가능성이 있는 노드 ((1, 2)의 4-이웃)를 나열하라.
- (b) 각 이웃의 새 rhs 를 계산하고 inconsistent 여부를 판별하라.

(a) (1, 2)의 4-이웃: $\{(1, 1), (1, 3), (2, 2)\}$.

(b) 차단 후 $g(1, 2) = \infty$. 각 이웃의 rhs 를 다시 계산:

- (1, 1): 시작점, $rhs(s_{start}) = 0$ 고정. $g = 0 = rhs \rightarrow$ **consistent (불변)**.
- (1, 3): 4-이웃 (1, 2), (2, 3). $rhs = \min\{g(1, 2) + 1, g(2, 3) + 1\} = \min\{\infty, 4\} = 4$.
 $g(1, 3) = 2 \neq 4 \rightarrow$ **inconsistent** ($g < rhs$, underconsistent).
 LPA*는 $g(1, 3) \leftarrow \infty$ 로 설정 후 이웃들로 propagate.
- (2, 2): 4-이웃 (1, 2), (2, 1), (2, 3), (3, 2). $rhs = \min\{\infty, 2, 4, 4\} = 2$.
 $g(2, 2) = 2 = rhs \rightarrow$ **consistent (불변)**. (2, 1)을 통한 대체 경로가 동일 거리.

결론: (1, 3) 한 개만 underconsistent. (2, 1) 같은 대체 경로 덕분에 (2, 2)는 영향 없음. LPA* “변경 부분만 재계산”의 핵심 — 차단된 셀이 어떤 이웃의 유일한 최단경로에 있을 때만 inconsistent 발생.

[보조] k_m 이 없으면



D* Lite에서 key modifier k_m 이 도입된 이유와, 만약 k_m 이 없으면 어떤 비효율이 생기는지 설명하라.

D* Lite의 key는 $k_1(s) = \min(g, rhs) + h(s_{start}, s) + k_m$. 로봇이 매 step 움직이면 s_{start} 가 바뀌므로 모든 **priority queue** 노드의 h 값이 바뀐다. 이를 매번 반영하려면 queue 전체를 재정렬 ($O(N \log N)$) — 비효율.

k_m 트릭: 누적 이동거리 $k_m += h(s_{last}, s_{curr})$ 를 유지하고, 새로 삽입되는 노드에만 k_m 을 더한 **key**를 부여. 기존 노드는 그대로 두어도 상대적 순서가 보존 $\Rightarrow O(\log N)$ 삽입만 발생, 전체 재정렬 불필요.

Part II — Constraints & Controllability (L04–L05)

5 L04. Nonholonomic Constraints

[메인] Simple car의 Pfaffian과 Lie bracket



Simple car 운동학: $\dot{x} = v \cos \theta, \dot{y} = v \sin \theta, \dot{\theta} = \omega$.

- (a) 후륜 미끄럼 없음 조건에서 Pfaffian 제약 $A(q)\dot{q} = 0$ 을 유도하라.
- (b) Control-affine $\dot{q} = g_1 v + g_2 \omega$ 의 g_1, g_2 를 쓰고 $[g_1, g_2]$ 를 계산하라.
- (c) $\det[g_1 \ g_2 \ [g_1, g_2]]$ 를 계산해 nonholonomic임을 보여라.

(a) 후륜은 heading θ 방향으로만 움직임 $\Rightarrow$ 속도 벡터가 θ 에 수직 성분 0:

$$(\dot{x}, \dot{y}) \cdot (-\sin \theta, \cos \theta) = -\dot{x} \sin \theta + \dot{y} \cos \theta = 0$$

$$A(q) = [\sin \theta \quad -\cos \theta \quad 0], \quad \dot{x} \sin \theta - \dot{y} \cos \theta = 0.$$

(b)

$$g_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \\ 0 \end{bmatrix}, \quad g_2 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

g_2 상수 $\Rightarrow \partial g_2 / \partial q = 0$.

$$\frac{\partial g_1}{\partial q} = \begin{bmatrix} 0 & 0 & -\sin \theta \\ 0 & 0 & \cos \theta \\ 0 & 0 & 0 \end{bmatrix}, \quad \frac{\partial g_1}{\partial q} g_2 = \begin{bmatrix} -\sin \theta \\ \cos \theta \\ 0 \end{bmatrix}.$$

$$[g_1, g_2] = 0 - \begin{bmatrix} -\sin \theta \\ \cos \theta \\ 0 \end{bmatrix} = \begin{bmatrix} \sin \theta \\ -\cos \theta \\ 0 \end{bmatrix}.$$

(c) 3행 2열 cofactor 전개 ($a_{32} = 1$, 나머지 0):

$$\det \begin{bmatrix} \cos \theta & 0 & \sin \theta \\ \sin \theta & 0 & -\cos \theta \\ 0 & 1 & 0 \end{bmatrix} = -1 \cdot \det \begin{bmatrix} \cos \theta & \sin \theta \\ \sin \theta & -\cos \theta \end{bmatrix} = -(-\cos^2 \theta - \sin^2 \theta) = 1 \neq 0.$$

$\dim \mathcal{L}(\Delta) = 3 = n$, Δ 는 **non-involutive** $\Rightarrow$ **nonholonomic**. □

[보조] 자동차 변종 비교



Tricycle, Simple car, Reeds-Shepp, Dubins의 입력 집합을 적고, 네 변종 중 최소 회전반경 $\rho_{\min}$ 개념이 의미 있는 것을 모두 골라라 (이유 설명).

변종	U_v	U_ϕ
Tricycle	$[-1, 1]$	$[-\pi/2, \pi/2]$
Simple car	$[-1, 1]$	$(-\phi_{\max}, \phi_{\max}), \phi_{\max} < \pi/2$
Reeds-Shepp	$\{-1, 0, 1\}$	$(-\phi_{\max}, \phi_{\max})$
Dubins	$\{0, 1\}$	$(-\phi_{\max}, \phi_{\max})$

$\rho_{\min} = L / \tan \phi_{\max}$. Tricycle은 $u_\phi = \pm \pi/2$ 로 제자리 회전 가능 $\Rightarrow \tan(\pi/2) = \infty \Rightarrow \rho_{\min} = 0$, 무의미.

의미 있는 것: Simple car, Reeds-Shepp, Dubins (모두 $\phi_{\max} < \pi/2$ 로 유한 양의 $\rho_{\min}$).

6 L05. Controllability & Chained Form

[메인] Unicycle chained form 검증

★★★★★

Unicycle $\dot{x} = v \cos \theta$, $\dot{y} = v \sin \theta$, $\dot{\theta} = \omega$. 좌표/입력 변환

$$z_1 = \theta, \quad z_2 = x \cos \theta + y \sin \theta, \quad z_3 = x \sin \theta - y \cos \theta,$$

$$u_1 = \omega, \quad u_2 = v - z_3 u_1$$

가 chained form $\dot{z}_1 = u_1$, $\dot{z}_2 = u_2$, $\dot{z}_3 = z_2 u_1$ 을 만족함을 보여라.

$$\dot{z}_1: \dot{z}_1 = \dot{\theta} = \omega = u_1 \checkmark.$$

$$\dot{z}_2:$$

$$\dot{z}_2 = \dot{x} \cos \theta - x \sin \theta \dot{\theta} + \dot{y} \sin \theta + y \cos \theta \dot{\theta}$$

$$\dot{x} = v \cos \theta, \dot{y} = v \sin \theta \text{ 대입:}$$

$$= v \cos^2 \theta + v \sin^2 \theta + \omega(y \cos \theta - x \sin \theta) = v - z_3 \omega = v - z_3 u_1.$$

$$u_2 = v - z_3 u_1 \text{ 로 정의했으므로 } \dot{z}_2 = u_2 \checkmark.$$

$$\dot{z}_3:$$

$$\dot{z}_3 = \dot{x} \sin \theta + x \cos \theta \dot{\theta} - \dot{y} \cos \theta + y \sin \theta \dot{\theta} = v \cos \theta \sin \theta - v \sin \theta \cos \theta + \omega(x \cos \theta + y \sin \theta) = z_2 u_1.$$

$\checkmark$. 따라서 $(z_1, z_2, z_3, u_1, u_2)$ 가 3-state 2-input chained form. $\square$

[보조] Chow–Rashevskii로 Unicycle controllability

★★

Unicycle ($n = 3, m = 2$) 가 small-time locally controllable 임을 Chow–Rashevskii 정리로 보여라.

Driftless $\dot{q} = g_1 v + g_2 \omega$. L04 메인에서 계산:

$$g_1 = [\cos \theta, \sin \theta, 0]^T, \quad g_2 = [0, 0, 1]^T, \quad [g_1, g_2] = [\sin \theta, -\cos \theta, 0]^T.$$

$$\det[g_1 \ g_2 \ [g_1, g_2]] = 1 \neq 0 \text{ 이므로 } \dim \mathcal{L}(\Delta) = 3 = n.$$

Chow–Rashevskii에 의해 small-time locally controllable. $\square$

해석: 입력 (v, ω) 만으로는 순간 sideways 운동 불가. 하지만 Lie bracket $[g_1, g_2]$ 가 sideways 방향을 생성 $\Rightarrow$ 4-단계 motion primitive (translate-rotate-untranslate-unrotate)로 임의의 위치 도달 가능. 평행주차의 원리.

[보조2] Bicycle-like (자동차) chained form 검증

★★★★★

Rear-wheel drive 자동차, wheelbase L :

$$\dot{x} = v \cos \theta, \quad \dot{y} = v \sin \theta, \quad \dot{\theta} = (v/L) \tan \phi, \quad \dot{\phi} = \omega.$$

$$q = (x, y, \theta, \phi).$$

(a) g_1, g_2 를 쓰고 $g_3 = [g_1, g_2]$, $g_4 = [g_1, g_3]$ 를 계산하라.

(b) $\det[g_1 \ g_2 \ g_3 \ g_4]$ 를 구하고 nonholonomic 임을 보여라.

(a)

$$g_1 = \begin{bmatrix} \cos \theta \\ \sin \theta \\ \tan \phi/L \\ 0 \end{bmatrix}, \quad g_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}.$$

g_2 상수 $\Rightarrow \partial g_2 / \partial q = 0$. g_1 의 Jacobian에서 ϕ 미분만 nonzero (q 의 4번째 변수):

$$\frac{\partial g_1}{\partial \phi} = \begin{bmatrix} 0 \\ 0 \\ \sec^2 \phi / L \\ 0 \end{bmatrix}, \quad \frac{\partial g_1}{\partial q} g_2 = \frac{\partial g_1}{\partial \phi}.$$

$$g_3 = [g_1, g_2] = -\frac{\partial g_1}{\partial q} g_2 = \begin{bmatrix} 0 \\ 0 \\ -1/(L \cos^2 \phi) \\ 0 \end{bmatrix}.$$

g_3 는 ϕ 만 의존, g_1 의 4번째 성분이 0이므로 $\partial g_3 / \partial q \cdot g_1 = 0$. $\partial g_1 / \partial q \cdot g_3$ 는 $g_3^{(3)} = -1/(L \cos^2 \phi)$ 효과:

$$\frac{\partial g_1}{\partial q} g_3 = g_3^{(3)} \cdot \frac{\partial g_1}{\partial \theta} = -\frac{1}{L \cos^2 \phi} \begin{bmatrix} -\sin \theta \\ \cos \theta \\ 0 \\ 0 \end{bmatrix}.$$

$$g_4 = [g_1, g_3] = -\frac{\partial g_1}{\partial q} g_3 = \begin{bmatrix} -\sin \theta / (L \cos^2 \phi) \\ \cos \theta / (L \cos^2 \phi) \\ 0 \\ 0 \end{bmatrix}.$$

(b) 4번째 행 cofactor 전개 ($a_{42} = 1$, 나머지 0). Cofactor 부호 $(-1)^{4+2} = +1$:

$$\det[g_1 \ g_2 \ g_3 \ g_4] = + \det \begin{bmatrix} \cos \theta & 0 & -\sin \theta / (L \cos^2 \phi) \\ \sin \theta & 0 & \cos \theta / (L \cos^2 \phi) \\ \tan \phi / L & -1 / (L \cos^2 \phi) & 0 \end{bmatrix}.$$

3×3에서 2번째 열 cofactor ($a_{32} = -1/(L \cos^2 \phi)$, 부호 $(-1)^{3+2} = -1$):

$$= (-1) \cdot \left(-\frac{1}{L \cos^2 \phi}\right) \det \begin{bmatrix} \cos \theta & -\sin \theta / (L \cos^2 \phi) \\ \sin \theta & \cos \theta / (L \cos^2 \phi) \end{bmatrix} = \frac{1}{L \cos^2 \phi} \cdot \frac{\cos^2 \theta + \sin^2 \theta}{L \cos^2 \phi}.$$

$$\det[g_1 \ g_2 \ g_3 \ g_4] = +\frac{1}{L^2 \cos^4 \phi} \neq 0 \quad (\cos \phi \neq 0).$$

따라서 $\dim \mathcal{L}(\Delta) = 4 = n \Rightarrow$ **nonholonomic, controllable** (Chow–Rashevskii). 이 결과가 chained form 변환 $z_1 = x, z_2 = \sec^3 \theta \tan \phi / L, z_3 = \tan \theta, z_4 = y$ 의 정당성을 뒷받침. (HW2 1(a)–(c)와 직결.)

Part III — Trajectory & Collision (L06–L09)

7 L06. Polynomial Trajectory & Bézier

[메인] $J = \int (P^{(3)})^2 dt$ 최소화

★★★★★

비용 $J = \int_0^T (P^{(3)}(t))^2 dt$ 를 최소화하는 다항식 $P(t)$ 의 차수와 필요한 BC 개수를 Euler-Lagrange equation으로 유도하라.

$\mathcal{L} = (P^{(3)})^2$. 일반 Euler-Lagrange:

$$\sum_{k=0}^r (-1)^k \frac{d^k}{dt^k} \frac{\partial \mathcal{L}}{\partial x^{(k)}} = 0.$$

$\partial \mathcal{L} / \partial P^{(3)} = 2P^{(3)}$, 나머지 0. 따라서:

$$(-1)^3 \frac{d^3}{dt^3} (2P^{(3)}) = 0 \Rightarrow \frac{d^6}{dt^6} P(t) = 0.$$

$\Rightarrow P$ 는 5차 다항식. 계수 6개 $\Rightarrow$ BC 6개 필요 (양 끝에서 위치, 속도, 가속도 각각). 이것이 **minimum-jerk trajectory** (quintic Hermite).

[보조2] Minimum-snap trajectory 차수

★★★★★

비용 $J = \int_0^T (P^{(4)}(t))^2 dt$ (snap의 제곱) 최소화에서 최적 $P(t)$ 의 차수와 BC 개수를 Euler-Lagrange로 유도하고, minimum-jerk와 비교하라.

$\mathcal{L} = (P^{(4)})^2$. Higher-order Euler-Lagrange:

$$\sum_{k=0}^4 (-1)^k \frac{d^k}{dt^k} \frac{\partial \mathcal{L}}{\partial P^{(k)}} = 0.$$

$\partial \mathcal{L} / \partial P^{(4)} = 2P^{(4)}$ 만 nonzero:

$$(-1)^4 \frac{d^4}{dt^4} (2P^{(4)}) = 0 \Rightarrow \frac{d^8}{dt^8} P(t) = 0.$$

$\Rightarrow P$ 는 7차 다항식. 계수 8개 $\Rightarrow$ BC 8개. 양 끝에서 위치, 속도, 가속도, jerk 각각 ($4 \times 2 = 8$). Minimum-jerk vs minimum-snap 비교:

비용	차수	BC 개수	양 끝 BC
$\int (P^{(3)})^2 dt$ (min-jerk)	5 (quintic)	6	위치, 속도, 가속도
$\int (P^{(4)})^2 dt$ (min-snap)	7 (septic)	8	+ jerk

Quadrotor flatness 연계: $\ddot{\mathbf{p}}$ 가 모멘트 M 을 결정 $\Rightarrow$ snap 최소화 = 입력 노력 최소화의 자연스러운 척도 (Mellinger & Kumar 2011).

[보조] Bézier C^2 연속

★★★

두 큐빅 Bézier ($N = 3$) segment의 control points가 P_0, P_1, P_2, P_3 과 Q_0, Q_1, Q_2, Q_3 . 접합점에서 C^0, C^1, C^2 연속을 만족하려면 Q_0, Q_1, Q_2 를 P_1, P_2, P_3 로 표현하라.

Bézier hodograph: r' 의 control point는 $N(b_{k+1} - b_k)$.

- C^0 : $r_1(1) = r_2(0) \Rightarrow \boxed{Q_0 = P_3}$.
- C^1 : $r'_1(1) = r'_2(0)$. $3(P_3 - P_2) = 3(Q_1 - Q_0) \Rightarrow \boxed{Q_1 = 2P_3 - P_2}$.
- C^2 : $r''_1(1) = r''_2(0)$. $6(P_3 - 2P_2 + P_1) = 6(Q_2 - 2Q_1 + Q_0)$.
 $Q_0 = P_3, Q_1 = 2P_3 - P_2$ 대입:

$$Q_2 = (P_3 - 2P_2 + P_1) + 2(2P_3 - P_2) - P_3 = \boxed{4P_3 - 4P_2 + P_1}.$$

8 L07. Collision Checking

[메인] SAT으로 두 사각형 충돌 판정

★★

축 정렬 사각형 $A = [0, 2] \times [0, 2]$ 와 $B = [1, 3] \times [2, 4]$ 의 충돌 여부를 SAT으로 판정하라.

두 사각형 모두 축 정렬이므로 분리축 후보는 x 축 $u_x = (1, 0)$ 과 y 축 $u_y = (0, 1)$ 만.

- u_x 사영: $A \rightarrow [0, 2], B \rightarrow [1, 3]$. 교집합 $[1, 2]$, 겹침.
- u_y 사영: $A \rightarrow [0, 2], B \rightarrow [2, 4]$. 교집합 $\{2\}$, 한 점.

두 축 모두 disjoint 아님 $\Rightarrow$ 충돌 (정확히 경계 접촉). 분리축이 없으므로 SAT은 collision으로 판정.
 (만약 $B = [3, 5] \times [2, 4]$ 였다면 u_x 사영 $[3, 5]$ 가 $A = [0, 2]$ 와 disjoint $\Rightarrow$ no collision.)

[보조] GJK 알고리즘 단계

★

GJK가 $A \cap B$ 판정에서 사용하는 핵심 아이디어 (Minkowski 차)와 support function을 설명하고, 다음 순서로 시뮬레이션:

초기 방향 $d_0 = (1, 0)$. Support point 차례로 $a_1 = (4, -2)$, 새 방향 d_1 결정 후 $a_2 = (-7, 2)$, 다시 $a_3 = (0, 4)$. 이때 simplex가 원점을 포함하는지 어떻게 판단하는가?

핵심: $A \cap B \neq \emptyset \iff 0 \in A - B$ (Minkowski 차).

$$\text{support}_{A-B}(d) = \text{support}_A(d) - \text{support}_B(-d) = \arg \max_{x \in A-B} d^T x.$$

Simulation:

1. $a_1 = (4, -2)$. Simplex $\{a_1\}$. 원점은 simplex 외부 $\Rightarrow$ 다음 방향 $d_1 = -a_1 = (-4, 2)$.
2. $a_2 = (-7, 2)$. Simplex $\{a_1, a_2\}$. 원점이 segment 외부 $\Rightarrow$ 원점 방향의 수직 분할로 새 방향 $d_2 \propto (24, 66)$.

3. $a_3 = (0, 4)$. Simplex $\{a_1, a_2, a_3\} =$ 삼각형.

원점 포함 판정: 삼각형 $\{(4, -2), (-7, 2), (0, 4)\}$ 의 barycentric 좌표로 $0 = \lambda_1 a_1 + \lambda_2 a_2 + \lambda_3 a_3$, $\sum \lambda_i = 1$ 풀이. $\lambda_1 \approx 0.56, \lambda_2 \approx 0.32, \lambda_3 \approx 0.12$ — 모두 ≥ 0 , 합 1이므로 0이 삼각형 내부 $\Rightarrow$ collision.

(만약 어떤 $\lambda_i < 0$ 이면 원점은 그 vertex 반대편이므로 그쪽 edge로 simplex를 축소하고 새 support point 계산.)

9 L08. CHOMP

[메인] Projection $(I - \hat{x}'\hat{x}'^T)$ 의 의미

★★

CHOMP obstacle gradient:

$$\frac{\delta J}{\delta x} = \|x'\| [(I - \hat{x}'\hat{x}'^T)\nabla c - c(x)\kappa].$$

- (a) 행렬 $(I - \hat{x}'\hat{x}'^T)$ 가 임의의 벡터에 작용할 때 기하학적으로 무엇을 하는가?
 (b) 왜 이 projection 이 obstacle gradient 에 등장하는가? Arc-length parameterization 과 연관지어 설명하라.

- (a) $\hat{x}' = x'/\|x'\|$ 는 trajectory 의 단위 접선벡터. $(I - \hat{x}'\hat{x}'^T)v$ 는 v 를 접선에 수직인 평면으로 정사영한 벡터:

$$v = \underbrace{(\hat{x}'^T v)\hat{x}'}_{\text{tangential}} + \underbrace{(I - \hat{x}'\hat{x}'^T)v}_{\text{normal}}.$$

- (b) Obstacle cost 를 arc-length 로 적분 (시간 무관) 하기 위해 $\int c(x)\|x'\| dt$ 형태. 이때 trajectory 를 접선 방향으로 reparameterize (속도 조정) 해도 cost 불변이어야 한다.
 기존 ∇c 를 그대로 쓰면 접선 방향 변형도 cost 를 바꿀 수 있음. Projection 을 취하면 접선 성분이 제거 $\Rightarrow$ 오직 trajectory 를 옆으로 밀어내는 변형 (normal) 만 남는다. 이는 reparameterization invariance 를 보장하고 더 부드러운 obstacle avoidance 를 유도.
 추가 항 $-c(x)\kappa$ 는 curvature 가 큰 곳에서 trajectory 를 곧게 펴는 역할 (path length 단축).

[보조] K_2 Finite difference matrix

★

$\xi = (q_1, q_2, q_3, q_4)^T$ (1차원 4 waypoint). K_2 finite difference operator 를 명시적으로 행렬로 쓰고 $K_2\xi$ 의 의미를 설명하라.

K_2 의 i -th 행은 가속도 $(q_{i+1} - 2q_i + q_{i-1})$. 강의안 정의에 따라:

$$K_2 = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -2 & 1 & 0 & 0 \\ 1 & -2 & 1 & 0 \\ 0 & 1 & -2 & 1 \end{bmatrix}, \quad K_2\xi = \begin{bmatrix} q_1 \\ -2q_1 + q_2 \\ q_1 - 2q_2 + q_3 \\ q_2 - 2q_3 + q_4 \end{bmatrix}.$$

$\|K_2\xi\|^2$ 는 trajectory 의 discrete acceleration 제곱합 $\Rightarrow$ minimum-acceleration smoothness penalty. $A = K_2^T K_2 \succ 0$ — CHOMP 의 metric matrix. 이 A^{-1} 로 gradient 를 “smoothing” 하여 covariant update 를 만든다.

10 L09. Quadrotor Flatness & SFC

[메인] Quadrotor thrust 와 body z-axis

★★★★

질량 $m = 1$, 중력 $g = 10$. $\mathbf{e}_3 = [0, 0, 1]^T$.

- (a) 호버 $\ddot{\mathbf{p}} = [0, 0, 0]^T$ — thrust f 와 body z-축 $\mathbf{b}_3$ 를 구하라.
 (b) $\ddot{\mathbf{p}} = [3, 0, 6]^T$ (위 + 앞 방향 가속) — $f, \mathbf{b}_3$ 를 구하라.

공식: $\mathbf{a} = g\mathbf{e}_3 - \ddot{\mathbf{p}}$, $f = m\|\mathbf{a}\|$, $\mathbf{b}_3 = \mathbf{a}/\|\mathbf{a}\|$.

(a) $\mathbf{a} = [0, 0, 10] - [0, 0, 0] = [0, 0, 10]$. $\|\mathbf{a}\| = 10$.

$$f = 10, \quad \mathbf{b}_3 = [0, 0, 1]^T$$

수직 상방, 중력과 평형.

(b) $\mathbf{a} = [0, 0, 10] - [3, 0, 6] = [-3, 0, 4]$. $\|\mathbf{a}\| = \sqrt{9 + 16} = 5$.

$$f = 5, \quad \mathbf{b}_3 = [-3, 0, 4]^T/5$$

의미: thrust 방향 $\mathbf{b}_3$ 는 가속 요구와 중력 보상의 합력 방향. 평탄출력 (x, y, z, ψ) 의 2차 미분만으로 $\mathbf{b}_3$ (attitude 2자유도)와 f 가 결정됨 $\Rightarrow$ flatness.

[보조] SFC ellipsoid tangent plane



Ellipsoid $\xi(E, d) = \{p : (p - d)^T E (p - d) \leq 1\}$ ($E \succ 0$)의 경계점 p^c 에서 접평면이 $a^T p \leq b$ 꼴, $a = 2E(p^c - d)$, $b = a^T p^c$ 임을 보여라.

Ellipsoid 경계: $g(p) = (p - d)^T E (p - d) - 1 = 0$. 접평면의 법선 $= \nabla g(p^c) = 2E(p^c - d) =: a$.
 접평면 방정식: $a^T(p - p^c) = 0 \iff a^T p = a^T p^c =: b$.
 내부 결정: 중심 $p = d$ 대입. $a^T d = 2(p^c - d)^T E d$.

$$b - a^T d = a^T p^c - a^T d = 2(p^c - d)^T E (p^c - d) = 2 \cdot 1 = 2 > 0$$

$\Rightarrow$ 중심 d 는 $a^T p < b$ 쪽. Ellipsoid 전체가 **halfspace** $\{p : a^T p \leq b\}$ 에 포함되고, hyperplane은 ellipsoid의 **지지 hyperplane**.
 (강의안의 $E^{-1}E^{-T}$ 표기는 affine map E 로 unit ball을 변환한 ellipsoid 정의를 사용한 경우. 본 문제의 표기와 동치.)

Part IV — Optimal Control & MPC (L10–L12)

11 L10. LQR / iLQR

[메인] Riccati 한 step 손계산



2D 시스템 $A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$, $B = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ (double integrator, $\Delta t = 1$). $Q = I_2$, $R = 1$, $P_2 = Q = I_2$ ($N = 2$).
 K_1, P_1 을 한 단계 Riccati로 손계산하라.

$$K_k = (R + B^T P_{k+1} B)^{-1} B^T P_{k+1} A,$$

$$P_k = Q + A^T P_{k+1} A - A^T P_{k+1} B (R + B^T P_{k+1} B)^{-1} B^T P_{k+1} A.$$

$$P_2 = I.$$

$$1. B^T P_2 B = B^T B = 1. R + B^T P_2 B = 2.$$

$$2. B^T P_2 A = (0, 1) \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = (0, 1).$$

$$3. K_1 = (1/2)(0, 1) = (0, 1/2).$$

$$4. A^T P_2 A = A^T A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}.$$

$$5. A^T P_2 B = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}. A^T P_2 B \cdot (B^T P_2 A)/2 = \frac{1}{2} \begin{pmatrix} 0 \\ 1 \end{pmatrix} (0, 1) = \frac{1}{2} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}.$$

$$6. P_1 = I + \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 5/2 \end{pmatrix}.$$

$$K_1 = (0, 1/2), \quad P_1 = \begin{pmatrix} 2 & 1 \\ 1 & 5/2 \end{pmatrix}.$$

해석: 최적 제어 $u^* = -K_1 x = -(1/2)v$. 속도에 비례한 감속 ($B = e_2$ 구조이므로 위치는 직접 제어되지 않음).

[보조] iLQR의 k, K 역할과 line search

★★

iLQR backward pass에서 $\delta u^* = k + K\delta x$, $k = -Q_{uu}^{-1}Q_u$, $K = -Q_{uu}^{-1}Q_{ux}$.

(a) k 와 K 각각이 forward rollout $u^{\text{new}} = \bar{u} + \alpha k + K(x^{\text{new}} - \bar{x})$ 에서 어떤 역할을 하는가?

(b) $\alpha \in (0, 1]$ line search가 왜 필요한가?

(a)

- k (feedforward): 명목 trajectory에서 **open-loop** 개선 방향. $\bar{u}$ 에 더해져 더 낮은 cost로 이동. $\bar{u}$ 가 이미 최적이면 $Q_u = 0 \Rightarrow k = 0$.

- K (feedback): state 편차 $x^{\text{new}} - \bar{x}$ 를 보정하는 **closed-loop gain**. forward rollout 중 비선형성으로 nominal에서 벗어나도 안정화. LQR의 시간가변 feedback gain과 동일한 구조.

(b) Backward pass는 nominal 주위의 **2차 근사**. Full step $\alpha = 1$ 은 근사가 정확할 때만 보장. 비선형성이 크거나 nominal에서 멀어지면 cost가 오히려 증가할 수 있다.

$\rightarrow \alpha$ 를 1부터 줄여가며 (0.5, 0.25, ...) 실제 cost가 감소하는 첫 α 채택. 또한 backward pass에 LM regularization $Q_{uu} + \lambda I$ 를 추가해 안정화.

12 L11. Linear MPC Stability

[메인] Recursive feasibility 핵심 증명

★★★★★

Linear MPC의 recursive feasibility를 다음 단계로 증명하라:

(i) 시각 t 에서 optimal control sequence $\mathbf{u}_t^* = (u_0^*, \dots, u_{N-1}^*)$, predicted states $(x_0^*, \dots, x_N^*)$, $x_N^* \in \mathcal{X}_f$.

(ii) u_0^* 적용 후 $x_{t+1} = x_1^*$. 시각 $t+1$ 에서 후보 sequence $\tilde{\mathbf{u}} = (u_1^*, \dots, u_{N-1}^*, Kx_N^*)$ 가 feasible함을 보여라.

$\tilde{\mathbf{u}}$ 적용 시 predicted states:

$$\tilde{x}_i = x_{i+1}^*, \quad i = 0, \dots, N-1, \quad \tilde{x}_N = A_K x_N^* \quad (A_K = A + BK).$$

Feasibility 점검:

1. 입력 제약 $\tilde{u}_i \in \mathcal{U}$:

- $i = 0, \dots, N-2$: $\tilde{u}_i = u_{i+1}^* \in \mathcal{U}$ (시각 t 의 optimal). ✓
- $i = N-1$: $\tilde{u}_{N-1} = Kx_N^*$. Terminal set 정의 $K\mathcal{X}_f \subseteq \mathcal{U} + x_N^* \in \mathcal{X}_f \Rightarrow Kx_N^* \in \mathcal{U}$. ✓

2. 상태 제약 $\tilde{x}_i \in \mathcal{X}$:

- $i = 0, \dots, N-1$: $\tilde{x}_i = x_{i+1}^* \in \mathcal{X}$ ✓.
- $i = N$: $\tilde{x}_N = A_K x_N^* \in \mathcal{X}_f \subseteq \mathcal{X}$ (아래 (3) 사용). ✓

3. **Terminal** $\tilde{x}_N \in \mathcal{X}_f$: Terminal set **invariance** $A_K \mathcal{X}_f \subseteq \mathcal{X}_f$ 로부터 $A_K x_N^* \in \mathcal{X}_f$. ✓
 따라서 $\tilde{u}$ 는 시각 $t+1$ 에서 feasible. MPC는 이보다 같거나 더 좋은 optimal을 찾을 수 있으므로 **feasibility**는 보존된다. □
 핵심: terminal set의 **invariance under K** 가 결정적.

[보조] Condensed vs Sparse QP



(a) Condensed (변수 U), sparse (변수 Z) 두 형식의 변수 수를 N, n, m 로 표현하라.
 (b) Horizon이 길어질수록 어느 쪽이 유리한가? 이유를 한 단락으로.

(a)
 • Condensed: $|U| = Nm$.
 • Sparse: $|Z| = (N+1)n + Nm$.
 (b) Condensed는 $X = \Phi x_t + \Gamma U$ 형태로 다이내믹스를 소거. Γ 가 **lower triangular block matrix**로 dense ($\Gamma_{ij} = A^{i-j-1}B$). Hessian $H = \Gamma^T \bar{Q} \Gamma + \bar{R}$ 역시 dense. N 증가 시 $O((Nm)^2)$ 연산 비싸짐.
 Sparse는 변수는 많지만 equality constraint matrix A_{eq} 가 **block-banded** (인접 시점만 연결). KKT system도 banded $\Rightarrow O(N)$ **factorization** 가능 (Riccati-like 구조). Long horizon에서는 sparse가 효율적.

13 L12. NMPC & PMP

[메인] Costate recursion 유도



강의안 표준 식 $\lambda_k = \ell_x + F_x^T \lambda_{k+1}$ 이 직접 나오도록 multiplier 인덱스를 λ_{k+1} 로, 부호는 $F - x$ 방향으로 정한 Lagrangian:

$$\mathcal{L} = \sum_{k=0}^{N-1} \ell(x_k, u_k) + \ell_f(x_N) + \sum_{k=0}^{N-1} \lambda_{k+1}^T (F(x_k, u_k) - x_{k+1}).$$

$\partial \mathcal{L} / \partial x_N = 0$ 과 $\partial \mathcal{L} / \partial x_k = 0$ ($0 < k < N$)로부터 다음을 유도하라:

$$\lambda_N = \ell_{f,x}(x_N), \quad \lambda_k = \ell_x(x_k, u_k) + F_x(x_k, u_k)^T \lambda_{k+1}.$$

Terminal ($k = N$). x_N 이 등장하는 항: $\ell_f(x_N)$ 과 $\sum$ 의 $k = N-1$ 항에서 $-\lambda_N^T x_N$.

$$\frac{\partial \mathcal{L}}{\partial x_N} = \ell_{f,x}(x_N) - \lambda_N = 0 \quad \Rightarrow \quad \boxed{\lambda_N = \ell_{f,x}(x_N)}.$$

Internal ($0 < k < N$). x_k 가 등장하는 항:

- $\ell(x_k, u_k) \rightarrow \ell_x$
- $\lambda_{k+1}^T F(x_k, u_k)$ ($\sum$ 의 k 항) $\rightarrow F_x^T \lambda_{k+1}$
- $-\lambda_k^T x_k$ ($\sum$ 의 $k-1$ 항: $-x_{(k-1)+1} = -x_k$) $\rightarrow -\lambda_k$

$$\frac{\partial \mathcal{L}}{\partial x_k} = \ell_x + F_x^T \lambda_{k+1} - \lambda_k = 0 \quad \Rightarrow \quad \boxed{\lambda_k = \ell_x(x_k, u_k) + F_x(x_k, u_k)^T \lambda_{k+1}}.$$

해석: λ_k 는 시각 k 의 상태가 미래 cost에 미치는 **sensitivity** (costate). 역방향으로 F_x^T 로 propagate하면서 즉각 cost gradient ℓ_x 를 누적. PMP의 이산판.

연속시간 dynamics $\dot{x} = f(x, u)$ 를 Euler 이산화하면 $F(x, u) = x + \Delta t f(x, u)$, stage cost 는 $\Delta t \cdot \ell(x, u)$. 이산 NMPC의 1차 최적성 조건은

$$\lambda_k = \Delta t \ell_x(x_k, u_k) + F_x(x_k, u_k)^T \lambda_{k+1}, \quad \Delta t \ell_u(x_k, u_k) + F_u(x_k, u_k)^T \lambda_{k+1} = 0.$$

$\Delta t \rightarrow 0$ 극한을 취해 연속시간 **Pontryagin** 최소원리 식

$$\dot{\lambda} = -\frac{\partial H}{\partial x}, \quad \frac{\partial H}{\partial u} = 0, \quad H(x, u, \lambda) = \ell + \lambda^T f$$

가 나옴을 보여라.

Step 1 — Jacobian 대입. $F = I \cdot x + \Delta t f$ 이므로

$$F_x = I + \Delta t f_x, \quad F_u = \Delta t f_u.$$

Step 2 — Costate 식 정리. 대입하면

$$\lambda_k = \Delta t \ell_x + (I + \Delta t f_x)^T \lambda_{k+1} = \lambda_{k+1} + \Delta t (\ell_x + f_x^T \lambda_{k+1}).$$

양변에서 λ_{k+1} 를 빼고 Δt 로 나누면

$$\frac{\lambda_k - \lambda_{k+1}}{\Delta t} = \ell_x + f_x^T \lambda_{k+1}.$$

Step 3 — Limit $\Delta t \rightarrow 0$. $k \Delta t \rightarrow t$ 로 두고 $\lambda_k \rightarrow \lambda(t)$. 좌변의 backward difference 는 $-\dot{\lambda}(t)$:

$$-\dot{\lambda} = \ell_x + f_x^T \lambda.$$

$H = \ell + \lambda^T f$ 이면 $\partial_x H = \ell_x + f_x^T \lambda$:

$$\dot{\lambda}(t) = -\frac{\partial H}{\partial x}.$$

Step 4 — Control optimality. $\Delta t \ell_u + (\Delta t f_u)^T \lambda_{k+1} = 0$ 양변을 Δt 로 나누면

$$\ell_u + f_u^T \lambda = 0 \quad \Leftrightarrow \quad \frac{\partial H}{\partial u} = 0.$$

해석: 이산 NMPC의 FONC가 곧 PMP의 이산화. costate λ 는 상태가 미래 cost에 미치는 sensitivity로, Hamiltonian의 x -편미분에 음의 부호로 역방향 전파. DDP backward pass는 이 PMP의 직접 이산 구현이다.

연속시간 LQR: $\ell(x, u) = x^T Q x + u^T R u$, $f(x, u) = A x + B u$, $R \succ 0$. Hamiltonian을 쓰고, $\partial H / \partial u = 0$ 으로부터 최적 입력을 u 로 표현하라.

Hamiltonian:

$$H(x, u, \lambda) = \ell + \lambda^T f = x^T Q x + u^T R u + \lambda^T (A x + B u).$$

u stationary:

$$\frac{\partial H}{\partial u} = 2 R u + B^T \lambda = 0.$$

$R \succ 0$:

$$u^*(t) = -\frac{1}{2}R^{-1}B^T\lambda(t).$$

(이산판: $\lambda \rightarrow \lambda_{k+1}$.)

이 식과 costate $\dot{\lambda} = -\partial_x H = -2Qx - A^T\lambda$ 를 합치면 Hamiltonian system. Riccati ansatz $\lambda = 2Px$ 대입 시 P 가 **continuous-time ARE**를 만족:

$$A^TP + PA - PBR^{-1}B^TP + Q = 0.$$

$\Rightarrow$ LQR optimal gain $K_{\text{LQR}} = R^{-1}B^TP$. PMP와 Riccati 일치.

정리 + 출제 가능성 티어 (5단계)

티어	의미	문제 수
★★★★★	거의 확정적 출제	2
★★★★	매우 높음	6
★★★	높음	6
★★	중간	7
★	낮음	8

총 29문제 (L05, L06, L12에 보조2 추가).

L	메인	티어	보조	티어
00	Visibility/Voronoi 비교	★★★	Local minima + nav func	★★
01	A* trace	★★★	Admissible $\neq$ cons.	★★
02	RRT 의사코드	★	RRT* rewiring	★★★★
03	LPA* update	★	k_m 역할	★
04	Pfaffian + Lie bracket	★★★★★	차량 변종 비교	★
05	Unicycle chained form	★★★★★	Chow-Rashevskii / 자동차 chained	★★ / ★★★★★
06	Min-jerk 차수 유도	★★★★★	Bézier C^2 / Min-snap 차수	★★★★ / ★★★★★
07	SAT 두 사각형	★★	GJK trace	★
08	$(I - \hat{x}'\hat{x}'^T)$ 의미	★★	K_2 matrix	★
09	Quadrotor f, b_3	★★★★	Ellipsoid tangent	★
10	Riccati 한 step	★★★★★	iLQR k, K, α	★★
11	Recursive feasibility	★★★★★	Condensed vs Sparse	★
12	Costate recursion 유도	★★★★★	PMP on LQR / Discrete $\rightarrow$ Cont PMP 극한	★★ / ★★★★★

등급별 정리

★★★★★ 거의 확정적 출제 (2)

1. **L11** 메인 Recursive feasibility — MPC 안정성 핵심, 강의안에 자세히.
2. **L04** 메인 Pfaffian + Lie bracket — nonholonomic 핵심, HW 직결.
★★★★ 매우 높음 (6)
3. **L05** 메인 Unicycle chained form — HW2 직결 패턴.
4. **L05** 보조2 자동차 chained form (Lie bracket 4×4) — HW2 1(a)–(c) 직결.
5. **L10** 메인 Riccati 한 step — 순계산 표준 문제.
6. **L06** 메인 Min-jerk 차수 유도 — Euler-Lagrange 클래식.
7. **L12** 메인 Costate recursion 유도 — NMPC 핵심.
8. **L12** 보조2 Discrete $\rightarrow$ Continuous PMP 극한 — NMPC $\leftrightarrow$ PMP 본질.
★★★ 높음 (6)

9. **L01** 메인 A* trace — 손계산 클래식.
10. **L09** 메인 Quadrotor $f, \mathbf{b}_3$ — flatness 손계산.
11. **L00** 메인 Visibility / Voronoi 비교 — 개념 비교 단골.
12. **L06** 보조 Bézier C^2 — 트라젝토리 핵심.
13. **L06** 보조2 Min-snap 차수 유도 — min-jerk와의 일반화.
14. **L02** 보조 RRT* rewire + asymp. optimal — 식 + 직관.
★★ 중간 (7)
15. **L05** 보조 Chow–Rashevskii — Lie algebra 짧은 적용.
16. **L00** 보조 Local minima + nav func 4조건.
17. **L01** 보조 Admissible $\neq$ consistent — 미묘한 차이.
18. **L08** 메인 $(I - \hat{x}'\hat{x}'^T)$ projection 의미 — CHOMP 핵심.
19. **L10** 보조 iLQR k, K, α — 개념 설명.
20. **L12** 보조 PMP on LQR — 짧은 유도.
21. **L07** 메인 SAT 두 사각형 — 손계산.
★ 낮음 (8)
22. **L02** 메인 RRT 의사코드 — 단순 알고리즘 채우기.
23. **L03** 메인 LPA* update — 약간 복잡.
24. **L03** 보조 k_m 역할 — 개념 설명.
25. **L07** 보조 GJK trace — 약간 복잡.
26. **L04** 보조 자동차 변종 — 표 정리.
27. **L08** 보조 K_2 행렬 — 단순 작성.
28. **L09** 보조 ellipsoid tangent — 유도.
29. **L11** 보조 condensed vs sparse — 비교.

출제 패턴 추정

- 계산 문제 2–3개: L01 A* trace / L10 Riccati / L04 Lie bracket / L09 Quadrotor 중.
 - 유도 문제 1–2개: L06 min-jerk 차수 / L05 chained form / L12 costate or PMP 극한 중.
 - 증명/논리 1개: L11 recursive feasibility는 거의 확정.
 - 개념 비교 1개: L00 visibility vs Voronoi / L02 RRT vs RRT* 등.
 - 개념 서술 1개: L08 CHOMP projection / L09 flatness 의미 등.
- 총 29문제. 풀이는 cheat sheet 없이도 따라갈 수 있도록 단계별, 손계산 가능한 수치만 사용.